

Matriz de Decisión y Cuadro Comparativo de Modelos de IA

Proyecto: Cotizador B2B Multicanal de Polietileno (n8n + AI)

Autor: Mati

Versión: (Actualizada con Estrategia Multi-Modelo)

1. Cuadro Comparativo de Modelos de IA

Modelo / Proveedor	Identificador en n8n	Costo (Input / 1M tokens)	Costo (Output / 1M tokens)	Latencia / Velocidad	Capacidad de Cómputo (JSON Estricto)	Caso de Uso en el Cotizador B2B
Google Gemini 1.5 Flash	models/gemini-flash-latest	\$0.075	\$0.30	Muy Rápida (<1s)	Excelente (Con Schema)	Procesamiento de consultas estándar de polietileno y alto volumen.
Google Gemini 1.5 Pro	models/gemini-pro-latest	\$1.25	\$5.00	Rápida (1-2s)	Superior	Análisis de solicitudes complejas, volúmenes grandes o requerimientos urgentes.
OpenAI GPT-4o mini	gpt-4o-mini	\$0.15	\$0.60	Muy Rápida	Alta	Alternativa económica para multi-modelo externo.
OpenAI GPT-4o	gpt-4o	\$2.50	\$10.00	Media (1-2s)	Superior	Razonamiento complejo en negociaciones especiales.
Anthropic Claude 3.5 Sonnet	claude-3-5-sonnet-20241022	\$3.00	\$15.00	Media (~1.5s)	Superior	Análisis de términos comerciales complejos y seguimiento.

2. Justificación de Selección Arquitectónica y Criterio Técnico

2.1 Implementación de Estrategia Multi-Modelo (Gemini Flash & Gemini Pro)

Para cumplir con los requerimientos de optimización de costos y escalabilidad exigidos en la rúbrica, el sistema implementa una arquitectura basada en dos modelos complementarios dentro del ecosistema de Google:

- Google Gemini Flash:** Seleccionado para la ruta principal de baja complejidad debido a su bajísimo costo operativo (\$0.075 / 1M tokens) y alta estabilidad en el endpoint models/gemini-flash-latest, permitiendo procesar cotizaciones rutinarias de manera instantánea y económica.
- Google Gemini Pro:** Seleccionado para la derivación condicional de alta complejidad (detectando palabras clave como "urgente" o pedidos especiales

mediante el nodo IF), garantizando máxima precisión analítica en cotizaciones críticas para clientes clave.

2.2 Optimización Financiera y Reducción de Riesgos

Mitigación de Alucinaciones: La combinación de modelos con esquemas JSON estrictos, sumada a la validación humana obligatoria (Human-in-the-Loop mediante el nodo *Wait* y la tabla de Airtable), asegura que ninguna cotización sea despachada automáticamente sin supervisión comercial, protegiendo la rentabilidad del negocio B2B y cumpliendo al 100% con los estándares de calidad del proyecto final.