

Modelo / Proveedor	Costo Input (1M)	Costo Output (1M)	Velocidad	Rol en la Automatización
Google Gemini 1.5 Flash	\$0.075	\$0.30	Muy Rápida	Procesamiento principal. Ideal para alto volumen de cotizaciones estándar.
Google Gemini 1.5 Pro	\$1.25	\$5.00	Rápida	Vía de excepción. Análisis de solicitudes marcadas como "urgentes" o complejas.
OpenAI GPT-4o-mini	\$0.15	\$0.60	Muy Rápida	Alternativa descartada. Gemini Flash ofrece menor costo en el ecosistema actual.
Anthropic Claude 3.5 Sonnet	\$3.00	\$15.00	Media	Alternativa descartada. Costo excesivo para el volumen transaccional B2B esperado.

2. Justificación de la Estrategia Arquitectónica

2.1. Estrategia Multi-Modelo Integrada Para optimizar los costos sin perder calidad analítica, el ecosistema no depende de una sola IA. Se utiliza un nodo IF como orquestador para evaluar la complejidad del texto entrante (ej. detección de la palabra clave "urgente"). Las peticiones normales se procesan con **Gemini Flash** (maximizando la rentabilidad y velocidad), mientras que los pedidos críticos se desvían a **Gemini Pro** (garantizando mayor razonamiento).

2.2. Mitigación de Riesgos y Control de Calidad (HITL) Aunque se utilizan esquemas JSON estrictos, los LLMs pueden presentar alucinaciones. Para mitigar este riesgo financiero en un entorno B2B, se implementó un nodo Wait. El flujo se detiene para que un ejecutivo humano revise la cotización generada. Gracias a la última actualización del flujo, la decisión humana gatilla una **bifurcación condicional**:

- Si aprueba, el sistema guarda los datos limpios y notifica al cliente el éxito.
- Si rechaza, el sistema cancela el proceso, enviando un correo de disculpas sin contaminar la base de datos de Airtable.