

Matriz de Decisión y Cuadro Comparativo de Modelos de IA

1. Cuadro Comparativo de Modelos de IA

Modelo / Proveedor	Identificador API (Model ID)	Costo Input (USD / 1M tokens)	Costo Output (USD / 1M tokens)	Latencia / Velocidad	Precisión / Extracción JSON	Caso de Uso en el Cotizador B2B
Google Gemini 1.5 Flash <i>(Elegido)</i>	models/gemini-flash-latest	\$0.075	\$0.30	Ultra Alta (~0.3s)	Excelente (JSON Schema Rígido)	Modelo de Producción y Testing: Extracción de datos de solicitudes no estructuradas.
Google Gemini 1.5 Pro	models/gemini-pro-latest	\$1.25\$	\$5.00\$	Media (~1.0s)	Superior	Análisis de contratos largos, pliegos o licitaciones complejas.
OpenAI GPT-4o-mini	gpt-4o-mini	\$0.15\$	\$0.60\$	Muy Alta (~0.5s)	Muy Alta	Alternativa equivalente en el ecosistema OpenAI.
OpenAI GPT-4o	gpt-4o	\$2.50\$	\$10.00\$	Media (~1.2s)	Superior	Cotizaciones con variables dinámicas complejas.
Anthropic Claude 3.5 Sonnet	claude-3-5-sonnet-20240620	\$3.00\$	\$15.00\$	Media (~1.1s)	Excelente en formato	Redacción de correos comerciales personalizados de seguimiento.

2. Justificación de Selección Arquitectónica y Criterio Técnico

2.1 Selección del Modelo: Google Gemini (models/gemini-flash-latest)

Para la implementación y testing del cotizador B2B de polietileno, se seleccionó el modelo Google Gemini 1.5 Flash a través del endpoint models/gemini-flash-latest por los siguientes motivos técnicos y de negocio:

- Compatibilidad Directa con n8n: Durante las pruebas técnicas de integración, se identificó que el alias/endpoint models/gemini-flash-latest ofreció una estabilidad del 100% en las llamadas HTTP/SDK de n8n, evitando los errores de incompatibilidad o *deprecation* que presentan otros identificadores de versión fija.
- Optimización Financiera y Licenciamiento: Se aprovecharon los créditos/API key activos de Google Cloud, garantizando costo cero en la etapa de desarrollo y validación de la PoC (Prueba de Concepto). A tarifas estándar de producción, su costo (\$0.075 USD / 1M tokens) representa un ahorro del 50% frente a GPT-4o-mini y de más de un 95% frente a GPT-4o.
- Estructuración Estricta de Salida (JSON Output): El cotizador requiere transformar mensajes informales (email, WhatsApp) en un esquema estructurado (tipo de material PEAD/PEBD, micrones, cantidad en kg). models/gemini-flash-latest responde de forma nativa con el formato JSON esperado por el nodo posterior de cálculo.

3. Estrategias de Escalabilidad y Optimización para Producción

- Procesamiento Masivo mediante Batch API (Procesamiento por Lotes): Para solicitudes masivas o procesamiento nocturno que no requiera respuesta en tiempo real, se implementará el procesamiento por lotes (*Batch API*), lo que genera un 50% de descuento directo en el consumo de tokens.
- Pre-filtrado Determinista en n8n (Principio BPA): Siguiendo la regla "*Primero optimizar, luego automatizar*", el flujo ejecuta un filtro determinista previo (Nodo

F/Code) que verifica la presencia de datos mínimos. Si la solicitud está vacía o es spam, la ejecución se detiene sin consumir llamadas a la API de Gemini.